

Praktikum Compilerbau

Wintersemester 2018/19

Ulrich Schöpp

(Dank an Andreas Abel, Robert Grabowski, Martin Hofmann
und Hans-Wolfgang Loidl)

Übersicht

Organisatorisches

Einführung

Lexikalische Analyse

Syntaxanalyse

Semantische Analyse

Organisatorisches

Das Praktikum richtet sich grob nach dem Buch

Modern Compiler Implementation in Java von Andrew Appel,
Cambridge University Press, 2005, 2. Auflage

Es wird ein Compiler für *MiniJava*, eine Teilmenge von Java, entwickelt.

- Implementierungssprache: Java, Haskell, Rust, OCaml, ...
- Zielarchitektur: x86

Jede Woche wird die Implementierung ein Stück weiterentwickelt.

- Vorlesungsteil (Theorie)
- Übungsteil (praktische Umsetzung)

Programmierung in Gruppen à zwei Teilnehmern.

Die Zeit in der Übung wird i.A. nicht ausreichen; Sie müssen noch ca. 4h/Woche für selbstständiges Programmieren veranschlagen.

Benotung durch eine Endabnahme des Programmierprojekts.

- Anforderung: Funktionierender Compiler von MiniJava nach Assembler-Code.
- Die Abnahme wird auch mündliche Fragen zu dem in der Vorlesung vermittelten Stoff enthalten.

- Mo 15.10. Einführung; Interpreter
- Mo 22.10. Lexikalische Analyse und Parsing
- Mo 29.10. Abstrakte Syntax und Parser
- Mo 5.11. Semantische Analyse

Milestone 1: Parser und Typchecker

- Mo 12.11. Zwischensprachen
- Mo 19.11. Activation records
- Mo 26.11. Basisblöcke

Milestone 2: Übersetzung in Zwischensprache

- Mo 3.12. Instruktionsauswahl
- Mo 10.12. Aktivitätsanalyse (liveness analysis)

Milestone 3: Übersetzung in Assembler mit Reg.variablen

- Mo 17.12. Registerverteilung
- Mo 7.1. Garbage Collection
- Mo 14.1. Static Single Assignment Form
- Mo 21.1. Optimierungen
- Mo 28.1. (optionales Thema)

Milestone 4: Fertiger Compiler

- Feb. Endabnahmen

Einführung

MiniJava

MiniJava ist eine kleine Teilmenge von Java

- Typen: `int`, `int[]`, `boolean`
- minimale Anzahl von Anweisungen: `if`, `while`
- Objekte und (optional) Vererbung, aber kein Überladen, keine statischen Methoden außer `main`
- einfaches Typsystem (keine Generics)
- Standardbibliothek:
 - `void System.out.println(int)`
 - `void System.out.write(int)`
 - `int System.in.read()`
- gleiche Semantik wie Java

Aufgaben eines MiniJava-Compilers

Übersetzung von Quellcode (MiniJava-Quelltext) in Maschinsprache (Assembler).


- Überprüfung, ob der Eingabetext ein korrektes MiniJava Programm ist.
 - Lexikalische Analyse und Syntaxanalyse
 - Semantische Analyse (Typüberprüfung und Sichtbarkeitsbereiche)

Ausgabe von informativen Fehlermeldungen bei inkorrektter Eingabe.

- Übersetzung in Maschinsprache
 - feste Anzahl von Maschinenregistern, wenige einfache Instruktionen, Kontrollfluss nur durch Sprünge, direkter Speicherzugriff
 - effizienter, kompakter Code
 - ...



Aufbau eines Compilers

Compiler bestehen üblicherweise aus *Front-End* und *Back-End*.




Zwischensprache(n)

- abstrakter Datentyp, leichter zu behandeln als Strings
- weniger komplex als Eingabesprache \Rightarrow Transformationen und Optimierungen leichter implementierbar
- Zusammenfassung ähnlicher Fälle, z.B. Kompilation von `for`- und `while`-Schleifen ähnlich.
- Kombination mehrerer Quellsprachen und Zielarchitekturen



Aufbau eines Compilers

Moderne Compiler sind als Verkettung mehrerer Transformationen zwischen verschiedenen Zwischensprachen implementiert.



(IR — Intermediate Representation)

- Zwischensprachen nähern sich Schrittweise dem Maschinencode an.
- Optimierungsschritte auf Ebene der Zwischensprachen

Aufbau eines Compilers

Erstes Ziel beim Compilerbau ist die **Korrektheit** des Compilers.

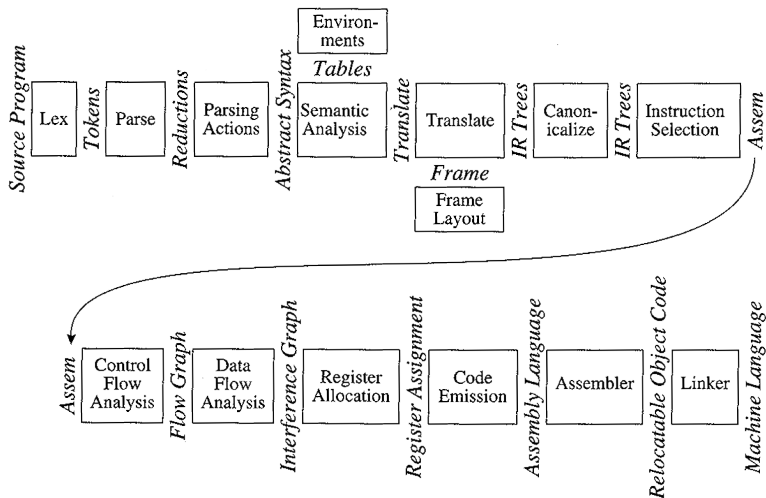
Die Aufteilung in eine Folge einfacher Transformationen hilft, die Korrektheit sicherzustellen.

- Kleine Transformationen sind übersichtlicher und leichter zu entwickeln als größere.
- Die einzelnen Transformationen sind unabhängig testbar.
- Zwischenergebnisse können überprüft werden, z.B. durch Zwischensprachen mit statischer Typüberprüfung.
- Zwischensprachen liefern klare Schnittstellen zur Arbeitsteilung und Wiederverwendung.

Prioritäten

- safety-first
- small is beautiful

Aufbau des MiniJava-Compilers



Zwischensprachen


Quelltext als String

```
"class Factorial{  
    public static void main(String[] a){  
        System.out.println(new Fac().ComputeFac(10));  
    }  
}
```

```
class Fac {  
  
    public int ComputeFac(int num){  
        int num_aux;  
        if (num < 1)  
            num_aux = 1;  
        else  
            num_aux = num * (this.ComputeFac(num-1));  
        return num_aux;  
    }  
}"
```

Zwischensprachen

Abstrakte Syntax




Zwischensprachen

IR: Abstraktionsebene vergleichbar mit C

```
LFac$ComputeFac(2) {  
  CJUMP(LT, PARAM(1), CONST(1), L$0, L$1)  
  LABEL(L$1)  
  MOVE(TEMP(t5), BINOP(MUL, PARAM(1),  
    CALL(NAME(LFac$ComputeFac),  
      PARAM(0),  
      BINOP(MINUS, PARAM(1), CONST(1))))))  
  JUMP(NAME(L$2), L$2)  
  LABEL(L$0)  
  MOVE(TEMP(t5), CONST(1))  
  LABEL(L$2)  
  MOVE(TEMP(t4), TEMP(t5))  
  return t4  
}
```


Zwischensprachen

IR Trees: Zwischensprachen brauchen keine konkrete Syntax und werden intern durch Syntaxbäume gespeichert.



```
CJUMP(LT, x, CONST(5), z, t);  
LABEL(z);  
CJUMP(GT, a, b, t f)
```

Zwischensprachen

Assembler mit beliebig vielen Registern

Lmain:

push %ebp

mov %ebp, %esp

sub %esp, 4

L\$\$205:

mov t309,42

mov t146,%ebx

mov t147,%esi

mov t148,%edi

mov t310,4

push t310

call L_halloc_obj

mov t311,%eax

add %esp,4

mov t145,t311

Zwischensprachen

Assembler

Lmain:

push %ebp

mov %ebp, %esp

sub %esp, 8

L\$\$205:

mov %eax,42

mov %eax,%ebx

mov DWORD PTR [%ebp - 4],%eax

mov %eax,4

push %eax

call L_halloc_obj

add %esp,4

mov %ebx,%eax

mov %eax,4

Praktikumsteil heute

Aufwärmung am Beispiel von Straightline-Programmen

- Repräsentierung abstrakter Syntax in Java
- Visitor Pattern

Aufgabe bis zum nächsten Mal:

- Gruppen finden
- Entwicklungsumgebung einrichten
- Ein Projekt für den MiniJava-Compiler auf `gitlab.cip.ifi.lmu.de` einrichten.

Abstrakte Syntax

Beispiel: arithmetische Ausdrücke

Konkrete Syntax

5 + (1 + 2 * 3) * 4

Abstrakte Syntax

In EBNF

$$Exp ::= num \mid Exp + Exp \mid Exp * Exp$$

In Haskell

```
data Exp = Num Int | Plus Exp Exp | Times Exp Exp
```

```
example = Plus (Num 5) (Plus (Num 1) (Times (Num 2) (Num 3)))
```

Abstrakte Syntax (Haskell)

```
data Exp = Num Int | Plus Exp Exp | Times Exp Exp
```

```
example = Plus (Num 5) (Plus (Num 1) (Times (Num 2) (Num 3)))
```

Interpreter:

```
eval :: Exp -> Int
```

```
eval (Num x) = x
```

```
eval (Plus e1 e2) = eval e1 + eval e2
```

```
eval (Times e1 e2) = eval e1 * eval e2
```

Beispiel: eval example wertet zu 12 aus.

Abstrakte Syntax (Haskell)

```
data Exp = Num Int | Plus Exp Exp | Times Exp Exp
```

```
example = Plus (Num 5) (Plus (Num 1) (Times (Num 2) (Num 3)))
```

Umwandlung in Strings:

```
toString :: Exp -> String
```

```
toString (Num x) = show x
```

```
toString (Plus e1 e2) =
```

```
    "(" ++ toString e1 ++ ")" + "(" ++ toString e2 ++ ")"
```

```
toString (Times e1 e2) =
```

```
    "(" ++ toString e1 ++ ")" * "(" ++ toString e2 ++ ")"
```

Beispiel: `toString example` wertet zu

`"(5) + ((1) + ((2) * (3)))"` aus.

Abstrakte Syntax (Java)

Composite Pattern

```
abstract class Exp {}
```

```
final class NumExp extends Exp {  
    final int value;  
    NumExp(int value) { this.value = value; }  
}
```

```
final class PlusExp extends Exp {  
    final Exp left;  
    final Exp right;  
    PlusExp(Exp left, Exp right) {  
        this.left = left;  
        this.right = right;  
    }  
}
```



```
final class TimesExp extends Exp {  
    final Exp left;  
    final Exp right;  
    TimesExp(Exp left, Exp right) {  
        this.left = left;  
        this.right = right;  
    }  
}
```

- Eine abstrakte Klasse für jedes Nichtterminalsymbol.
- Eine Unterklasse für jede Produktion.

Abstrakte Syntax (Java) — Funktionen

Möchte man Funktionen wie `eval` oder `toString` implementieren, kann man zu den Syntax-Klassen neue Funktionen hinzufügen.

```
abstract class Exp {  
    int eval();  
    String toString();  
}
```

```
final class NumExp extends Exp {  
    final int value;  
    NumExp(int value) { this.value = value; }  
    int eval() { return value; }  
    String toString() { return "" + value; }  
}
```

```
final class PlusExp extends Exp {  
    final Exp left;  
    final Exp right;  
    BinaryExp(Exp left, Exp right) { ... }  
  
    int eval() {  
        return left.eval() + right.eval();  
    }  
  
    String toString() {  
        return "(" + left.toString()  
            + ") + ("  
            + right.toString()  
            + ")";  
    }  
}  
...
```

Probleme dieses Ansatzes:

- Der Quellcode für `eval` und `toString` ist jeweils über viele verschiedene Klassen verstreut.
- Für jede neue Funktion müssen die Klassen der abstrakten Syntax geändert werden.
(problematisch für Programmbibliotheken, Trennung in Front- und Backend im Compiler)

Standardlösung: **Visitor Pattern**

Visitor Pattern

Eine generischer Ansatz zum Ausführen von Operationen auf Werten einer Composite-Datenstruktur.

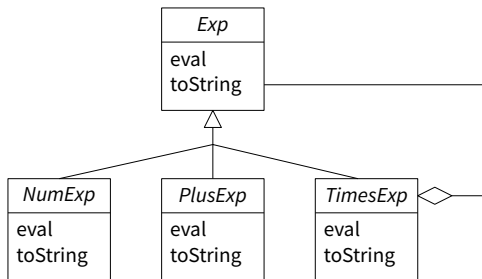
- Fördert eine *funktionsorientierte Sichtweise*: der Code für eine Operation auf einer gesamten Datenstruktur wird in einem Modul zusammengefasst.
- Fördert die Erweiterbarkeit von Programmen.
 - Implementierung neuer Operationen ohne Veränderung der Datenstruktur.
 - Beim Hinzufügen einer neuen Operation können keine Fälle vergessen werden.

Visitor Pattern

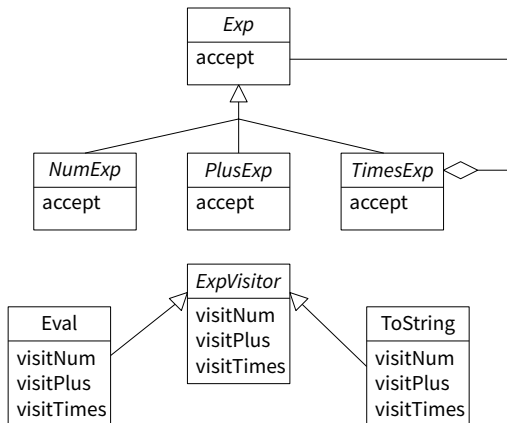
Idee:

- Sammle die Definitionen der Operationen auf der Objektstruktur in einem Visitor-Objekt.
- Ersetze die verschiedenen Operationen durch eine einzige accept-Methode.

Unser Beispiel



wird zu:



`accept(v)` in `NumExp` ist durch `{v.visitNum(this)}` implementiert, usw.

⇒ Auslagerung der Methodendefinitionen in Visitor-Objekte.

```
abstract class Exp {  
    abstract <T> T accept(ExpVisitor<T> v);  
}  
  
final class NumExp extends Exp {  
    ...  
    <T> T accept(ExpVisitor<T> v) { return v.visitNum(this);}  
}  
  
final class PlusExp extends Exp {  
    ...  
    <T> T accept(ExpVisitor<T> v) { return v.visitPlus(this);}  
}  
  
final class TimesExp extends Exp {  
    ...  
    <T> T accept(ExpVisitor<T> v) { return v.visitTimes(this);}  
}
```



```
abstract class ExpVisitor<T> {  
    abstract T visitNum(NumExp c);  
    abstract T visitPlus(PlusExp p);  
    abstract T visitTimes(TimesExp t);  
}
```

Funktionen für arithmetische Ausdrücke können nun in zentral in einem ExpVisitor-Objekt aufgeschrieben werden, ohne die Syntax ändern zu müssen.

```
class EvalVisitor implements ExpVisitor<Integer> {  
  
    public Integer visitNum(NumExp c) {  
        return c.value;  
    }  
    public Integer visitPlus(PlusExp p) {  
        return p.left.accept(this) + p.right.accept(this);  
    }  
    public Integer visitTimes(PlusExp p) {  
        return p.left.accept(this) * p.right.accept(this);  
    }  
}
```

Verwendung:

```
Exp example = new ExpPlus(new ExpNum(4), new ExpNum(3));  
int v = example.visit(new EvalVisitor());  
// v == 7
```

Straightline-Programme

Praktikumsaufgabe für heute: Implementierung eines Interpreters für *Straightline-Programme*.

- Straightline-Programme bestehen aus Zuweisungen, arithmetischen Ausdrücken, mehrstelligen Print-Anweisungen.

- Beispiel:

```
a := 5+3; b := (print(a, a-1), 10*a); print(b)
```

Ausgabe:

8 7

80

- Abstrakte Syntax als BNF Grammatik:

$$\begin{aligned} Stm &::= Stm; Stm \mid ident := Exp \mid \text{print}(ExpList) \\ Exp &::= ident \mid num \mid (Stm, Exp) \mid Exp Binop Exp \\ ExpList &::= Exp \mid Exp, ExpList \\ Binop &::= + \mid - \mid * \mid / \end{aligned}$$

Straightline Interpreter

Aufgabe für heute: Implementierung eines Interpreters für Straightline-Programme in Java.

Ein Programmrahmen ist im Praktikums-git gegeben.

Gegeben sind:

- Klassen für die abstrakte Syntax.
- Parser, der Straightline-Programmdateien in abstrakte Syntax einliest.
- Implementierung von ToString als Beispiel eines Visitors.
- Für die Auswertung von Programmen soll ein Eval-Visitor implementiert werden.

Operationelle Semantik

Die operationelle Semantik legt fest, wie sich Programme bei der Ausführung verhalten sollen.

Wichtiges Prinzip: *Kompositionalität*

Das Verhalten eines Programnteils wird aus dem Verhalten seiner Bestandteile erklärt.

Beispiel: Auswertung von $e_1 + e_2$

- Werte e_1 aus. Das Ergebnis ist eine Zahl i_1 .
- Werte e_2 aus. Das Ergebnis ist eine Zahl i_2 .
- Das Ergebnis der Auswertung ist die Zahl $i_1 + i_2$.

Beispiel: Auswertung von (s, e)

- Werte s aus. Dabei können Variablenwerte verändert werden.
- Werte e aus. Das Ergebnis ist eine Zahl i .
- Das Ergebnis der Auswertung ist die Zahl i .

Big-Step Reduktionsrelationen

Formalisierung der Auswertung durch Reduktionsrelationen.

- $s, \rho \Downarrow o, \rho'$: Wenn man die Anweisung s mit der Anfangsumgebung ρ (endliche Abbildung von Variablen auf Zahlen) ausführt, dann werden die Ausgabe in o (endlicher String) gemacht und am Ende ist die Umgebung ρ' .
- $e, \rho \Downarrow i, o, \rho'$: Wenn man den Ausdruck e in der Anfangsumgebung ρ auswertet, dann werden dabei die Ausgaben in o gemacht, der Ergebniswert ist i und am Ende ist die Umgebung ρ' .

Operationelle Semantik

Anweisungen

$$\frac{s_1, \rho_1 \Downarrow o_1, \rho_2 \quad s_2, \rho_2 \Downarrow o_2, \rho_3}{s_1; s_2, \rho_1 \Downarrow o_1 o_2, \rho_3} \quad \frac{e, \rho_1 \Downarrow i, o, \rho_2}{x := e, \rho_1 \Downarrow o, \rho_2 [x := i]}$$

$$\frac{e_i, \rho_i \Downarrow v_i, o_i, \rho_{i+1} \text{ für } i = 1, \dots, n}{\text{print}(e_1, \dots, e_n), \rho_1 \Downarrow o_1 \dots o_n v_1 \sqcup v_2 \sqcup \dots \sqcup v_n \setminus n, \rho_{n+1}}$$

Ausdrücke

$$\frac{e_1, \rho_1 \Downarrow i_1, o_1, \rho_2 \quad e_2, \rho_2 \Downarrow i_2, o_2, \rho_3}{e_1 + e_2, \rho_1 \Downarrow i_1 + i_2, o_1 o_2, \rho_3}$$

$$\frac{s, \rho_1 \Downarrow o_1, \rho_2 \quad e, \rho_2 \Downarrow i, o_2, \rho_3}{(s, e), \rho_1 \Downarrow i, o_1 o_2, \rho_3}$$

Programmieraufgabe: Straightline Interpreter

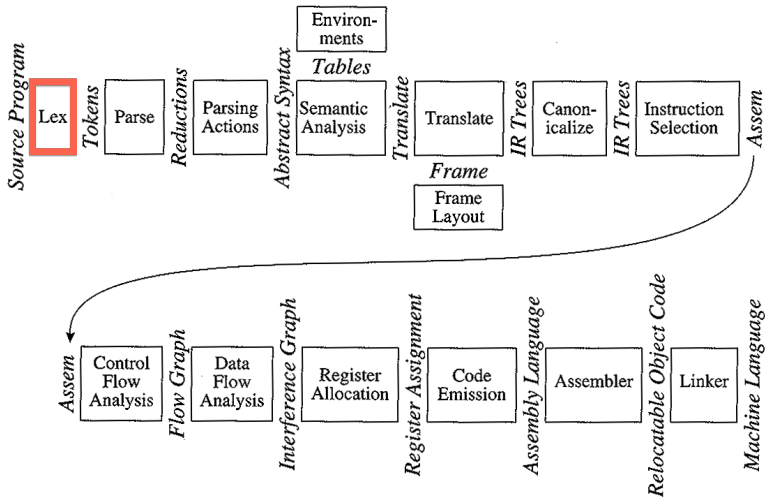
Aufgabe für heute: Implementieren Sie einen Interpreter für Straightline-Programme in Java.

Der Interpreter dient als Aufwärmübung. Besonders nützlich für den eigentlichen Compiler sind:

- **Datenrepräsentation:** Modellierung der abstrakten Syntax mittels einer Klassenhierarchie (*Composite Pattern*).
- **Programmiertechnik:** Iteration über diese Datenstruktur mittels eines *Visitor Pattern*.

Lexikalische Analyse

Lexikalische Analyse



Lexikalische Analyse

- Erste Phase der Kompilierung
- Die String-Eingabe (Quelltext) wird in eine Folge von *Tokens* umgewandelt.
- Leerzeichen und Kommentare werden dabei ignoriert.
- Die Tokens entsprechen den *Terminalsymbolen* der Grammatik der Sprache, können jedoch auch mit Werten versehen sein.

Was sind Tokens?

Beispiele:

"if"	→	IF
"!="	→	NEQ
"("	→	LPAREN
")"	→	RPAREN
"foo"	→	ID("foo")
"73"	→	INT(73)
"66.1"	→	REAL(66.1)

Keine Beispiele:

"/* bla */"	(Kommentar)
"#define NUM 5"	(Präprozessor Direktive)
"NUM"	(Makro)

Beispiel für die lexikalische Analyse

```
void match0(char *s) /* find a zero */  
{ if (!strncmp (s, ''0.0'', 3))  
    return 0.;  
}
```



VOID ID("match0") LPAREN CHAR STAR
ID(s) RPAREN LBRACE IF LPAREN
BANG ID("strncmp") LPAREN ID("s")
COMMA STRING("0.0") COMMA INT(3)
RPAREN RPAREN RETURN REAL(0.0)
SEMI RBRACE EOF

Implementierung eines Lexers

Schreibe einen Lexer von Hand

- nicht schwer, aber fehleranfällig und aufwändig

Benutze einen Lexer-Generator

- schnelle Implementierung eines Lexers
- liefert korrekten und effizienten Lexer
- Benutzung des Lexer-Generators benötigt Einarbeitungszeit

Lexer-Generatoren

Tokens werden durch reguläre Ausdrücke spezifiziert.

(→	LPAREN
print	→	PRINT
<i>digit digit*</i>	→	INT(ConvertToInt(yytext()))
<i>letter(letter + digit + { _ })*</i>	→	ID(yytext())

...

wobei $digit = \{0, \dots, 9\}$ und $letter = \{a, \dots, z, A, \dots, Z\}$.

- Die regulären Ausdrücke werden vom Lexer-Generator in einen endlichen Automaten umgewandelt, der zum Lesen der eigentlichen Eingabe benutzt wird.
- Automatische Lexergeneratoren wie flex, JFlex, alex, Ocamllex wandeln die Spezifikation in ein Lexer-Programm (als Quelltext) um, das einen entsprechenden Automaten simuliert.

Auflösung von Mehrdeutigkeiten

I.A. gibt es mehrere Möglichkeiten, eine Folge in Tokens zu zerlegen. Lexergeneratoren verwenden die folgenden zwei Regeln:

- **Längste Übereinstimmung:** Das längste Präfix, das zu irgendeinem der regulären Ausdrücke passt, wird das nächste Token.
- **Regelpriorität:** Wenn das nicht hilft, kommt die weiter oben stehende Regel zum Zug. Die Reihenfolge der Regeln spielt also eine Rolle.

```
print0  :  ID("print0") nicht PRINT INT(0)
print   :  PRINT nicht ID("print")
```


Funktionsweise von Lexer-Generatoren

Idee: Implementiere die lexikalische Analyse durch Abarbeitung der Eingabe mit einem endlichen Automaten (DFA). Der Automat kann ein Token am Anfang der Eingabe erkennen. \Rightarrow Zerlegung der Eingabe durch wiederholtes Ansetzen des Automaten.

- Jeder reguläre Ausdruck wird erst in einen NFA umgewandelt.
- Aus den einzelnen NFAs wird ein einziger NFA konstruiert, dessen Sprache die Vereinigung der Sprachen der NFAs ist.
- Mit der Potenzmengenkonstruktion und Minimierung wird der NFA in einen minimalen DFA umgewandelt.
- Jedem regulären Ausdruck ist ein Token zugeordnet. Die Endzustände des DFA für die Vereinigung werden mit den Tokens beschriftet, die beim Erreichen dieses Zustands gelesen worden sind. Mehrdeutigkeiten werden durch die Regelpriorität aufgelöst.

Funktionsweise von Lexer-Generatoren

Lexikalische Analyse

- Beginne mit dem Startzustand des Automaten und verfolge einen Lauf des Automaten.
- Zur Implementierung von „längste Übereinstimmung“ merkt man sich stets die Eingabeposition, bei der das letzte Mal ein Endzustand erreicht wurde.
- Kommt man in eine Sackgasse, d.h. kann das Wort nicht mehr vom Automaten akzeptiert werden, so bestimmt der letzte erreichte Endzustand das Token.
Man fängt dann an der folgenden Position wieder im Startzustand an, um das nächste Token zu lesen.

Lexergeneratoren

Ein Lexergenerator erzeugt aus einer Spezifikations-Datei einen Lexer in Form einer Java-Klasse (bzw. Haskell-Datei, ...) mit einer Methode/Funktion `next_token()`.

Jeder Aufruf von `next_token()` liefert das „Ergebnis“ zurück, welches zum nächsten verarbeiteten Teilwortes der Eingabe gehört. Normalerweise besteht dieses „Ergebnis“ aus dem Namen des Tokens und seinem Wert.

Die Spezifikations-Datei enthält Regeln der Form

$$regex \rightarrow \{code\}$$

wobei *code* Java-Code (oder Haskell-Code, ...) ist, der das „Ergebnis“ berechnet. Dieses Codefragment kann sich auf den (durch *regex*) verarbeiteten Text durch spezielle Funktionen und Variablen beziehen, z.B.: `yytext()` und `yypos`. Siehe Beispiel + Doku.

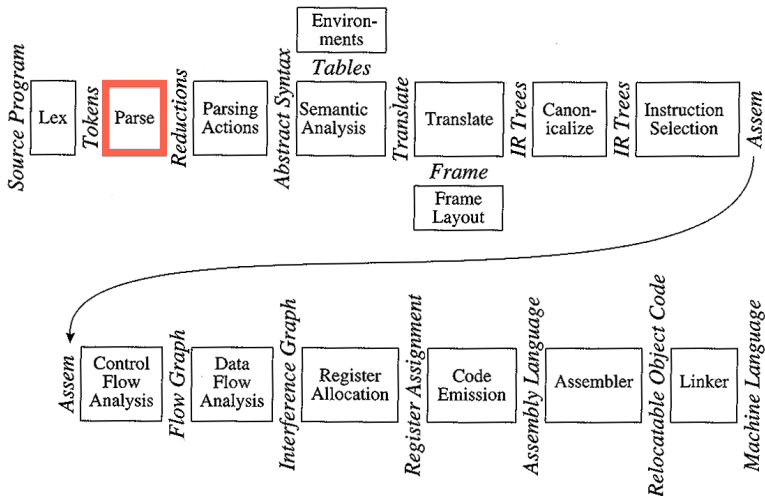
Zustände

In der Spezifikations-Datei können auch Zustände angegeben werden:

- Regeln können mit Zuständen beschriftet werden; sie dürfen dann nur in diesem Zustand angewandt werden.
- Im *code*-Abschnitt kann durch spezielle Befehle wie `yybegin()` der Zustand gewechselt werden.
- Man verwendet das, um geschachtelte Kommentare und Stringlitterale zu verarbeiten:
 - `/*` führt in einen „Kommentarzustand“.
 - Kommt `/*` im Kommentarzustand vor, so inkrementiere einen Tiefenzähler.
 - `*/` dekrementiert den Tiefenzähler oder führt wieder in den „Normalzustand“ zurück.
 - Ebenso führt `"` (Anführungszeichen) zu einem „Stringzustand“...

Syntaxanalyse

Syntaxanalyse



Syntaxanalyse

- Zweite Phase der Kompilierung
- Erkennen einer Folge von Tokens als eine Ableitung einer kontextfreien Grammatik
 - Überprüfung, ob Eingabe syntaktisch korrekt ist in Bezug auf die Programmiersprache
 - Umwandlung in einen Syntaxbaum (abstrakte Syntax, *abstract syntax tree*, AST).

Parsertechniken und -generatoren

- Laufzeit soll linear in der Eingabegröße sein:
 - Einschränkung auf spezielle Grammatiken (LL(1), LR(1), LALR(1)), für die effiziente Analysealgorithmen verfügbar sind.
- Diese Algorithmen (*Parser*) können automatisch aus einer formalen Grammatik erzeugt werden:
 - Parsergeneratoren: z.B. yacc, bison, ML-yacc, JavaCUP, JavaCC, ANTLR.
- Hier vorgestellt:
 - Parsertechniken LL(1), LR(1), LALR(1)
 - Parsergenerator JavaCUP

Wiederholung: Kontextfreie Grammatiken

- Kontextfreie Grammatik: $G = (\Sigma, V, P, S)$
 - $a, b, c, \dots \in \Sigma$: Terminalsymbole (Eingabesymbole, Tokens)
 - $X, Y, Z, \dots \in V$: Nichtterminalsymbole (Variablen)
 - P : Produktionen (Regeln) der Form $X \rightarrow \gamma$
 - $S \in V$: Startsymbol der Grammatik
- Symbolfolgen:
 - $u, v, w \in \Sigma^*$: Wörter (Folge von Nichtterminalsymbolen)
 - ϵ : leeres Wort
 - $\alpha, \beta, \gamma \in (\Sigma \cup V)^*$: Satzform (Folge von Terminal- und Nichtterminalsymbolen)
- Ableitungen:
 - Ableitungsrelation: $\alpha X \beta \Rightarrow \alpha \gamma \beta$ falls $X \rightarrow \gamma \in P$
 - Links-/Rechtsableitung: $w X \beta \Rightarrow_{\text{lm}} w \gamma \beta$ bzw. $\alpha X w \Rightarrow_{\text{rm}} \alpha \gamma w$
 - Sprache der Grammatik: $L(G) = \{w \in \Sigma^* \mid S \Rightarrow^* w\}$
 - Ableitungsbaum: Symbole aus γ als Unterknoten von X

LL(1)-Syntaxanalyse

Beispiel-Grammatik:

1. $S \rightarrow \text{if } E \text{ then } S \text{ else } S$
2. $S \rightarrow \text{begin } S L$
3. $S \rightarrow \text{print } E$
4. $L \rightarrow \text{end}$
5. $L \rightarrow ; S L$
6. $E \rightarrow \text{num} = \text{num}$

Ein Parser für diese Grammatik kann mit der Methode des rekursiven Abstiegs (*recursive descent*) gewonnen werden: Für jedes Nichtterminalsymbol gibt es eine Funktion, die gegen dieses analysiert.

In C

```
enum token {IF, THEN, ELSE, BEGIN, END, PRINT, SEMI, NUM, EQ};
extern enum token getToken(void);

enum token tok;
void advance() {tok=getToken();}
void eat(enum token t) {if (tok==t) advance(); else error();}

void S(void) {switch(tok) {
    case IF:    eat(IF); E(); eat(THEN); S();eat(ELSE); S(); break;
    case BEGIN: eat(BEGIN); S(); L(); break;
    case PRINT: eat(PRINT); E(); break;
    default:    error();}}
void L(void) {switch(tok) {
    case END:   eat(END); break;
    case SEMI:  eat(SEMI); S(); L(); break;
    default:   error();}}
void E(void) { eat(NUM); eat(EQ); eat(NUM); }
```

Manchmal funktioniert das nicht:

$S \rightarrow E \$$	$E \rightarrow E + T$	$T \rightarrow T * F$	$F \rightarrow \text{id}$
	$E \rightarrow E - T$	$T \rightarrow T / F$	$F \rightarrow \text{num}$
	$E \rightarrow T$	$T \rightarrow F$	$F \rightarrow (E)$

```
void S(void) { E(); eat(EOF); }
void E(void) {switch(tok) {
    case ?: E(); eat(PLUS); T(); break;
    case ?: E(); eat(MINUS); T(); break;
    case ?: T(); break;
    default: error(); }}
void T(void) {switch(tok) {
    case ?: T(); eat(TIMES); F(); break;
    case ?: T(); eat(DIV); F(); break;
    case ?: F(); break;
    default: error(); }}
```

LL(1)-Syntaxanalyse

- Eine Grammatik heißt LL(1), wenn ein Parse-Algorithmus basierend auf dem Prinzip des rekursiven Abstiegs für sie existiert.
- Der Parser muss anhand des nächsten zu lesenden Tokens (und der erwarteten linken Seite) in der Lage sein zu entscheiden, welche Produktion zu wählen ist.
- Die zu wählende Produktion kann zur Optimierung in einer Parser-Tabelle abgespeichert werden.
- Die LL(1) Sprachen sind genau die Sprachen, die von einem deterministischen Kellerautomaten mit einem Zustand akzeptiert werden.

LL(1)-Parser – Beispiel

Grammatik:

(1) $S \rightarrow F$

(2) $S \rightarrow (S+F)$

(3) $F \rightarrow a$

	()	a	+	\$
S	2		1		
F			3		

Eingabe: (a+a)

Stack	Input	Aktion
S \$	(a + a) \$	apply (2) $S \rightarrow (S+F)$
(S + F) \$	(a + a) \$	match '('
S + F) \$	a + a) \$	apply (1) $S \rightarrow F$
F + F) \$	a + a) \$	apply (3) $F \rightarrow a$
a + F) \$	a + a) \$	match 'a'
+ F) \$	+ a) \$	match '+'
F) \$	a) \$	apply (3) $F \rightarrow a$
a) \$	a) \$	apply (3) $F \rightarrow a$
) \$) \$	match ')'
\$	\$	match '\$' = accept

LL(1)-Syntaxanalyse

- Die Eingabe wird von links nach rechts verarbeitet, dabei wird eine Linksableitung vollzogen, und die Regelauswahl wird anhand des ersten Symbols der verbleibenden Eingabe und des obersten Stacksymbols entschieden.
 - LL(1): left-to-right parsing, left-most derivation, 1 token lookahead
- Verarbeitung beginnt beim Startsymbol (Top-down-Ansatz).
- Welche Produktion soll gewählt werden, bzw. wie wird die Tabelle erzeugt?
 - Ansatz: Wenn das nächste Eingabesymbol a ist und X auf Stack liegt (also erwartet wird), kommt diejenige Produktion für X infrage, die zu einer Ableitung mit a an der ersten Stelle führt.

Die First- und Follow-Mengen

- $\text{FIRST}(\gamma)$ ist die Menge aller Terminalsymbole, die als Anfänge von aus γ abgeleiteten Wörtern auftreten:

$$\text{FIRST}(\gamma) = \{a \mid \exists w. \gamma \Rightarrow^* aw\}$$

- $\text{FOLLOW}(X)$ ist die Menge der Terminalsymbole, die unmittelbar auf X folgen können:

$$\text{FOLLOW}(X) = \{a \mid \exists \alpha, \beta. S \Rightarrow^* \alpha X a \beta\}.$$

- $\text{nullable}(\gamma)$ bedeutet, dass das leere Wort aus γ abgeleitet werden kann:

$$\text{nullable}(\gamma) \iff \gamma \Rightarrow^* \epsilon.$$

Berechnung der First- und Follow-Mengen

Es genügt $\text{FIRST}(X)$ und $\text{nullable}(X)$ für Terminal- und Nichtterminalsymbole zu berechnen. Die Werte auf Satzformen sind davon eindeutig bestimmt.

- $\text{FIRST}(\epsilon) = \emptyset$, $\text{FIRST}(a\gamma) = \{a\}$, $\text{FIRST}(X\gamma) =$
if $\text{nullable}(X)$ **then** $\text{FIRST}(X) \cup \text{FIRST}(\gamma)$ **else** $\text{FIRST}(X)$.
- $\text{nullable}(\epsilon) = \text{true}$, $\text{nullable}(a\gamma) = \text{false}$,
 $\text{nullable}(X\gamma) = \text{nullable}(X) \wedge \text{nullable}(\gamma)$.

Berechnung der First- und Follow-Mengen

Die First- und Follow-Mengen, sowie das Nullable-Prädikat, lassen sich wie folgt iterativ berechnen:

Setze $\text{nullable}(a) := \text{false}$ und $\text{FIRST}(a) = \{a\}$ für alle Terminalsymbole a .

Setze $\text{nullable}(X) := \text{false}$ und $\text{FIRST}(X) = \text{FOLLOW}(X) = \emptyset$ für alle Nichtterminalsymbole X .

Gehe dann jede Produktion $X \rightarrow \gamma$ durch und ändere die Werte wie folgt, solange bis sich nichts mehr ändert:

- Wenn $\text{nullable}(\gamma)$, dann setze $\text{nullable}(X) := \text{true}$.
- $\text{FIRST}(X) := \text{FIRST}(X) \cup \text{FIRST}(\gamma)$.
- Für alle α, Y und β , so dass $\gamma = \alpha Y \beta$ und $\text{nullable}(\beta)$ gilt, setze $\text{FOLLOW}(Y) := \text{FOLLOW}(Y) \cup \text{FOLLOW}(X)$.
- Für alle α, Y, β, δ sowie $u \in \Sigma \cup V$, so dass $\gamma = \alpha Y \beta u \delta$ und $\text{nullable}(\beta)$ gilt, setze $\text{FOLLOW}(Y) := \text{FOLLOW}(Y) \cup \text{FIRST}(u)$.

Konstruktion des Parsers

Soll die Eingabe gegen X geparkt werden (d.h. wird X erwartet) und ist das nächste Token a , so kommt die Produktion $X \rightarrow \gamma$ in Frage, wenn

- $a \in \text{FIRST}(\gamma)$ oder
- $\text{nullable}(\gamma)$ und $a \in \text{FOLLOW}(X)$.

Die in Frage kommenden Produktionen werden in die LL-Tabelle in Zeile X und Spalte a geschrieben.

Kommen aufgrund dieser Regeln mehrere Produktionen in Frage, so ist die Grammatik nicht LL(1). Ansonsten spezifiziert die Tabelle den LL(1)-Parser, der die Grammatik erkennt.

Von LL(1) zu LL(k)

Der LL(1)-Parser entscheidet aufgrund des nächsten Tokens und der erwarteten linken Seite, welche Produktion zu wählen ist. Bei LL(k) bezieht man in diese Entscheidung die k nächsten Token mit ein.

Dementsprechend bestehen die First- und Follow-Mengen aus Wörtern der Länge k und werden dadurch recht groß. Durch Einschränkung der k -weiten Vorausschau auf bestimmte benutzerspezifizierte Stellen, lässt sich der Aufwand beherrschbar halten (z.B. bei ANTLR und JavaCC).

Wenn die Grammatik nicht LL(k) ist

Wenn eine Grammatik nicht LL(k) ist, gibt es dennoch Möglichkeiten, LL-Parser einzusetzen.

- Produktionsauswahl:
 - Kommen mehrere Produktionen infrage, kann man sich entweder auf eine festlegen, oder alle durchprobieren.
 - Damit ist der Parser aber nicht mehr unbedingt „vollständig“ in Bezug auf die Grammatik, d.h. es werden evtl. nicht alle gültigen Ableitungen erkannt.
 - Außerdem muss darauf geachtet werden, dass keine unendliche Rekursion stattfindet (bei linksrekursiven Grammatiken).
- Umformung der Grammatik:
 - Die Grammatik kann u.U. in eine LL(k)-Grammatik umgeformt werden, die die gleiche Sprache beschreibt.
 - Beispiel: Elimination von Linksrekursion.
 - Die Ableitungsbäume ändern sich dadurch natürlich.

Zusammenfassung LL(1)-Syntaxanalyse

- **Top-down parsing:** Das nächste Eingabesymbol und die erwartete linke Seite entscheiden, welche Produktion anzuwenden ist.
- Eine **LL(1)-Grammatik** liegt vor, wenn diese Entscheidung in eindeutiger Weise möglich ist. Die Entscheidung lässt sich dann mithilfe der First- und Follow-Mengen automatisieren.
- Der große **Vorteil** des LL(1)-Parsing ist die leichte Implementierbarkeit: auch ohne Parsergenerator kann ein rekursiver LL(1)-Parser leicht von Hand geschrieben werden, denn die Tabelle kann relativ einfach berechnet werden.
- Der **Nachteil** ist, dass die Grammatik vieler Programmiersprachen (auch MiniJava) nicht LL(k) ist.

Parsergenerator JavaCUP

- Parsergenerator: Grammatikspezifikation → Parser-Quellcode
- JavaCUP generiert LALR(1)-Parser als Java-Code (LALR-/LR-Parser werden nächstes Mal vorgestellt)
- Grammatikspezifikationen sind in die folgenden Abschnitte gegliedert:
 - Benutzerdeklarationen* (z.B. package statements, Hilfsfunktionen)
 - Parserdeklarationen* (z.B. Mengen von Grammatiksymbolen)
 - Produktionen*
- Beispiel für eine Produktion:
$$\text{exp} ::= \text{exp PLUS exp} \quad \{ : \text{Semantische Aktion} : \}$$

Die „semantische Aktion“ (Java-Code) wird ausgeführt, wenn die entsprechende Regel „feuert“. Üblicherweise wird dabei die AST-Repräsentation zusammengesetzt.

Beispielgrammatik

<i>Stm</i>	\rightarrow	<i>Stm;Stm</i>	(CompoundStm)
<i>Stm</i>	\rightarrow	<i>id :=Exp</i>	(AssignStm)
<i>Stm</i>	\rightarrow	<i>print (ExpList)</i>	(PrintStm)
<i>Exp</i>	\rightarrow	<i>id</i>	(IdExp)
<i>Exp</i>	\rightarrow	<i>num</i>	(NumExp)
<i>Exp</i>	\rightarrow	<i>Exp BinOp Exp</i>	(OpExp)
<i>Exp</i>	\rightarrow	<i>(Stm , Exp)</i>	(EseqExp)
<i>ExpList</i>	\rightarrow	<i>Exp , ExpList</i>	(PairExpList)
<i>ExpList</i>	\rightarrow	<i>Exp</i>	(LastExpList)
<i>BinOp</i>	\rightarrow	<i>+</i>	(Plus)
<i>BinOp</i>	\rightarrow	<i>-</i>	(Minus)
<i>BinOp</i>	\rightarrow	<i>*</i>	(Times)
<i>BinOp</i>	\rightarrow	<i>/</i>	(Div)

Implementierung in JavaCUP

```
package straightline;
import java_cup.runtime.*;

parser code { : <Hilfsfunktionen für den Parser> : }

terminal String ID; terminal Integer INT;
terminal COMMA, SEMI, LPAREN, RPAREN, PLUS, MINUS,
        TIMES, DIVIDE, ASSIGN, PRINT;

non terminal exp;
non terminal explist;
non terminal stm;

precedence left SEMI;
precedence nonassoc ASSIGN;
precedence left PLUS, MINUS;
precedence left TIMES, DIVIDE;
```

Implementierung in JavaCUP

start with stm;

```
exp ::=  exp TIMES exp {: :}  
      |  exp DIVIDE exp {: :}  
      |  exp PLUS exp  {: :}  
      |  exp MINUS exp  {: :}  
      |  INT  {: :}  
      |  ID   {: :}  
      |  LPAREN stm COMMA exp RPAREN {: :}  
      |  LPAREN exp RPAREN  {: :}  
      ;
```

```
explist ::= exp {: :}  
         | exp COMMA explist {: :}  
         ;
```

```
stm ::=  stm SEMI stm {: :}  
      |  PRINT LPAREN explist RPAREN {: :}  
      |  ID ASSIGN exp  {: :}  
      ;
```

Präzedenzdirektiven

Die obige Grammatik ist mehrdeutig. Präzedenzdirektiven werden hier zur Auflösung der Konflikte verwendet.

Die Direktive

```
precedence left SEMI;  
precedence left PLUS, MINUS;  
precedence left TIMES, DIVIDE;
```

besagt, dass TIMES, DIVIDE stärker als PLUS, MINUS binden, welche wiederum stärker als SEMI. Alle Operatoren assoziieren nach links.

Also wird $s1; s2; s3, x + y + z * w$ zu $(s1; (s2; s3)), ((x + y) + (z * w))$.

Verwendung von JavaCUP

JavaCUP wird als Kommandozeilentool verwendet.

```
java -jar java-cup-11a.jar --help
```

Der Aufruf

```
java -jar java-cup-11a.jar Parser.cup
```

- liest die Grammatik von Parser.cup,
- generiert eine Klasse sym.java mit Konstanten für alle Terminalsymbole,
- generiert eine Klasse parser.java mit dem eigentlichen Parser.

Die Namen von sym und parser können durch Kommandozeilenparameter geändert werden.

```
java -jar java-cup-11a.jar -parser Parser -symbols Parser_sym Parser.cup
```

Ihre heutige Aufgabe

Schreiben eines MiniJava-Lexers und -Parsers:

- MiniJava-Grammatik ist auf der Vorlesungsseite verlinkt.
- Verwenden Sie Lexer und Parser für StraightLine-Programme als Ausgangspunkt.
- Passen Sie den Lexer entsprechend der MiniJava-Syntax an.
- Passen Sie die Grammatik der MiniJava-Grammatik an.
- Parser soll zunächst nur akzeptierend sein:
 - keine semantischen Aktionen, keine AST-Klassenhierarchie
 - Operatorpräzedenzen wie in Java
 - Probleme wie Shift/Reduce-Konflikte können noch nicht behoben werden: Detaillierte Erklärung in der nächsten Sitzung.

LL- und LR-Parser

Letztes Mal: **LL(k)**-Parsing

- **L**eft-to-right parsing
- **L**eftmost derivation
- **k** token lookahead

Heute: **LR(k)**-Parsing

- **L**eft-to-right parsing
 - **R**ightmost derivation
 - **k** token lookahead
-
- **LL**-Parser sind leicht zu implementieren (rekursiver Abstieg)
 - **LR**-Parser erfassen mehr Grammatiken, insbesondere mit Linksrekursion, sind aber schwerer zu implementieren (braucht Parsergeneratoren)

Wiederholung: LL-Parser

Grammatik:

(1) $S \rightarrow F$

(2) $S \rightarrow (S+F)$

(3) $F \rightarrow a$

	()	a	+	\$
S	2		1		
F			3		

Eingabe: (a+a)

Stack	Input	Aktion
S \$	(a + a) \$	apply (2) $S \rightarrow (S+F)$
(S + F) \$	(a + a) \$	match '('
S + F) \$	a + a) \$	apply (1) $S \rightarrow F$
F + F) \$	a + a) \$	apply (3) $F \rightarrow a$
a + F) \$	a + a) \$	match 'a'
+ F) \$	+ a) \$	match '+'
F) \$	a) \$	apply (3) $F \rightarrow a$
a) \$	a) \$	apply (3) $F \rightarrow a$
) \$) \$	match ')'
\$	\$	match '\$' = accept

Der Lauf entspricht der Linksableitung

$S \rightarrow (S + F) \rightarrow (S + a) \rightarrow (F + a) \rightarrow (a + a).$

Der Parser muss die Produktion anhand der ersten k Zeichen des von ihr generierten Wortes auswählen.

LR-Parser

Grammatik:	Stack	Input	Aktion
(1) $S \rightarrow F$		(a + a) \$	shift '('
(2) $S \rightarrow (S+F)$	(a + a) \$	shift 'a'
(3) $F \rightarrow a$	(a	+ a) \$	reduce (3) $F \rightarrow a$
	(F	+ a) \$	apply (1) $S \rightarrow F$
Eingabe: (a+a)	(S	+ a) \$	shift '+'
	(S +	a) \$	shift 'a'
	(S + a) \$	reduce (3) $F \rightarrow a$
	(S + F) \$	shift ')'
	(S + F)	\$	reduce (2) $S \rightarrow (S+F)$
	S	\$	accept

Der Lauf entspricht der Rechtsableitung

$$S \rightarrow (S + F) \rightarrow (S + a) \rightarrow (S + a) \rightarrow (F + a) \rightarrow (a + a).$$

Regeln werden rückwärts angewendet (reduziert). Die Entscheidung wird erst getroffen, wenn die rechte Seite der Regel vollständig gelesen wurden.

LR-Syntaxanalyse

Der LR-Parser kann zu jedem Zeitpunkt eine der folgenden beiden Aktionen durchführen:

- *Shift*-Aktion: Ein weiteres Eingabesymbol lesen und auf den Stack legen.
- *Reduce*-Aktion: Eine Produktion auf die oberen Stacksymbole rückwärts anwenden, also den Stackinhalt $\sigma\gamma$ durch σX ersetzen, falls eine Produktion $X \rightarrow \gamma$ vorhanden ist.

Enthält der Stack nur das Startsymbol und wurde die gesamte Eingabe eingelesen, so wird akzeptiert.

Eine Grammatik ist per Definition LR(k), wenn die Entscheidung, welche der beiden Aktionen durchzuführen ist, allein aufgrund der bisher gelesenen Eingabe, sowie der nächsten k Eingabesymbole, getroffen werden kann.

LR-Syntaxanalyse

Aus technischen Gründen erweitern wir im Folgenden Grammatik um eine Produktion $S' \rightarrow S\$$, wobei $\$$ eine Markierung für das Ende der Eingabe ist.

Akzeptanz der Eingabe entspricht Reduktion mit dieser Regel.

LR-Parser – Beispiel Linksrekursion

Grammatik:	Stack	Input	Aktion
(0) $S' \rightarrow S\$$		tt \wedge tt \$	shift 'tt'
(1) $S \rightarrow S \wedge B$	tt	\wedge tt \$	reduce (4) $B \rightarrow tt$
(2) $S \rightarrow S \vee B$	B	\wedge tt \$	reduce (3) $S \rightarrow B$
(3) $S \rightarrow B$	S	\wedge tt \$	shift ' \wedge '
(4) $B \rightarrow tt$	S \wedge	tt \$	shift 'tt'
(5) $B \rightarrow ff$	S \wedge tt	\$	reduce (4) $B \rightarrow tt$
Eingabe: tt \wedge tt	S \wedge B	\$	reduce (1) $S \rightarrow S \wedge B$
	S	\$	accept

Die Grammatik ist LR(0): *Reduce* wann immer möglich, sonst *shift*.
 Wenn Stack=S und Eingabe=\$, dann *accept*.

LR-Parser – Beispiel Rechtsrekursion

Grammatik:	Stack	Eingabe	Aktion
(0) $S' \rightarrow S\$$		tt \wedge tt \$	shift 'tt'
(1) $S \rightarrow \mathbf{B} \wedge \mathbf{S}$	tt	\wedge tt \$	reduce (4) $B \rightarrow tt$
(2) $S \rightarrow \mathbf{B} \vee \mathbf{S}$	B	\wedge tt \$	shift ' \wedge '
(3) $S \rightarrow B$	B \wedge	tt \$	shift 'tt'
(4) $B \rightarrow tt$	B \wedge tt	\$	reduce (4) $B \rightarrow tt$
(5) $B \rightarrow ff$	B \wedge B	\$	reduce (3) $S \rightarrow B$
	B \wedge S	\$	reduce (1) $S \rightarrow B \wedge S$
Eingabe: tt \wedge tt	S	\$	accept

Die Grammatik ist nicht LR(0): Reduktion mit $S \rightarrow B$ statt Schiebens von ' \wedge ' würde in Sackgasse führen.

Die Grammatik ist aber immer noch LR(1).

Faustregel: **LR**-Parser mögen **L**inks-**R**ekursion.

Wann soll der Parser mit $X \rightarrow \gamma$ reduzieren?

- Wenn Reduktion möglich ist (d.h. γ oben auf dem Stack).
- Und wenn der Parsevorgang nach der Reduktion (bei geeignetem Rest der Eingabe) zur Akzeptanz führen kann. Bei LR(k) berücksichtigt man dabei die k folgenden Eingabesymbole $a_1 a_2 \dots a_k$.

Das heißt, folgende Situation liegt für mindestens ein w vor.

Stack	Input	Aktion
$\sigma\gamma$	$a_1 a_2 \dots a_k w \$$	

Wann soll der Parser mit $X \rightarrow \gamma$ reduzieren?

- Wenn Reduktion möglich ist (d.h. γ oben auf dem Stack).
- Und wenn der Parsevorgang nach der Reduktion (bei geeignetem Rest der Eingabe) zur Akzeptanz führen kann. Bei LR(k) berücksichtigt man dabei die k folgenden Eingabesymbole $a_1 a_2 \dots a_k$.

Das heißt, folgende Situation liegt für mindestens ein w vor.

Stack	Input	Aktion
$\sigma\gamma$	$a_1 a_2 \dots a_k w \$$	reduce $X \rightarrow \gamma$
σX	$a_1 a_2 \dots a_k w \$$	

Wann soll der Parser mit $X \rightarrow \gamma$ reduzieren?

- Wenn Reduktion möglich ist (d.h. γ oben auf dem Stack).
- Und wenn der Parsevorgang nach der Reduktion (bei geeignetem Rest der Eingabe) zur Akzeptanz führen kann. Bei LR(k) berücksichtigt man dabei die k folgenden Eingabesymbole $a_1 a_2 \dots a_k$.

Das heißt, folgende Situation liegt für mindestens ein w vor.

Stack	Input	Aktion
$\sigma\gamma$	$a_1 a_2 \dots a_k w \$$	reduce $X \rightarrow \gamma$
σX	$a_1 a_2 \dots a_k w \$$...
\vdots	\vdots	\vdots
S	$\$$	accept

Wann soll der Parser das nächste Symbol a shift-en?

Wenn der Parsevorgang dann noch erfolgreich abgeschlossen werden könnte, d.h. es wenn es bei geeigneter Eingabe später die Möglichkeit gibt, eine zielführende Produktion anzuwenden.

Hierbei werden keine weiteren Zeichen der Eingabe berücksichtigt.

Das heißt, folgende Situation liegt für mindestens ein w vor.

Stack	Input	Aktion
$\sigma \gamma$	$a \ w \ \$$	

Wann soll der Parser das nächste Symbol a shift-en?

Wenn der Parsevorgang dann noch erfolgreich abgeschlossen werden könnte, d.h. es wenn es bei geeigneter Eingabe später die Möglichkeit gibt, eine zielführende Produktion anzuwenden.

Hierbei werden keine weiteren Zeichen der Eingabe berücksichtigt.

Das heißt, folgende Situation liegt für mindestens ein w vor.

Stack	Input	Aktion
$\sigma \gamma$	a w \$	shift 'a'
$\sigma \gamma a$	w \$	

Wann soll der Parser das nächste Symbol a shift-en?

Wenn der Parsevorgang dann noch erfolgreich abgeschlossen werden könnte, d.h. es wenn es bei geeigneter Eingabe später die Möglichkeit gibt, eine zielführende Produktion anzuwenden.

Hierbei werden keine weiteren Zeichen der Eingabe berücksichtigt.

Das heißt, folgende Situation liegt für mindestens ein w vor.

Stack	Input	Aktion
$\sigma \gamma$	a w \$	shift 'a'
$\sigma \gamma a$	w \$...
\vdots	\vdots	\vdots
S	\$	accept

Das Wunder der LR(k) Syntaxanalyse

Die Entscheidung über die auszuführende Aktion kann durch einen endlichen Automaten übernommen werden.

- Der endliche Automat liest den *Stackinhalt*.
- Die Zustände des Automaten enthalten Informationen darüber, welche Produktionen im weiteren Verlauf noch erfolgreich ausgeführt werden könnten.
- Nach Lesen des Stackinhalts kann man am Zustand des Automaten erkennen, welche Aktion auszuführen ist.

Wir beschreiben den Aufbau des Automaten am Beispiel LR(0).

LR(0): Konstruktion des Automaten

Der Automat wird zunächst nichtdeterministisch konzipiert.

Die Zustände sind sogenannte **LR(0)-Items** und haben die Form

$$(X \rightarrow \alpha . \beta)$$

wobei $X \rightarrow \alpha \beta$ eine Produktion ist.

Informell drückt $(X \rightarrow \alpha . \beta)$ folgende Informationen über den Kellerautomaten aus:

- α liegt bereits oben auf dem Stack.
- Wenn durch weiteres Lesen der Eingabe noch β auf den Stack gelegt wird, dann kann die Reduktion mit $X \rightarrow \alpha \beta$ bei geeigneter Eingabe zur Akzeptanz führen.

LR(0): Transitionen des Automaten

Definiere die Zustandsübergänge des Automaten wie folgt:

- Startzustand des Automaten: $(S' \rightarrow .S\$)$
- $(X \rightarrow \alpha.s\beta) \xrightarrow{s} (X \rightarrow \alpha s.\beta), s \in \Sigma \cup V,$
- $(X \rightarrow \alpha.Y\beta) \xrightarrow{\epsilon} (Y \rightarrow .\delta), \text{ falls } Y \rightarrow \delta \text{ [Vervollständigung]}$

Man zeigt durch Induktion, dass der so definierte Automat tatsächlich die gewünschten Sprachen erkennt.

LR(0): Aktionen


Nun determinisiert man den Automaten und erhält so *Mengen von LR(0)-Items* als Zustände des Automaten.

Der Automat kann nun auf dem Stackinhalt des Kellerautomaten ausgeführt werden, um zu entscheiden, welche Aktion auszuführen ist.

- Enthält der erreichte Zustand das Item $(X \rightarrow \gamma.)$, so reduziert man mit $X \rightarrow \gamma$.
- Enthält der erreichte Zustand das Item $(X \rightarrow \alpha.a\beta)$, so wird a von der Eingabe geshiftet.

Gibt es mehrere Möglichkeiten, so liegt ein *Shift/Reduce*, beziehungsweise ein *Reduce/Reduce-Konflikt* vor und die Grammatik ist nicht LR(0).

LR(0): Automat für Linksrekursion



Regeln:

- (0) $S' \rightarrow S\$$
- (1) $S \rightarrow S \wedge B$
- (3) $S \rightarrow B$
- (4) $B \rightarrow tt$

Zustand 0: shift (tt)

Zustand 1: shift (\wedge)

Zustand 2: shift (tt)

Zustand 3: reduce (mit Regel 3)

Zustand 4: reduce (mit Regel 4)

Zustand 5: reduce (mit Regel 1)

Beispiel

Regeln:	Stack	Input	Zustand
(0) $S' \rightarrow S\$$		tt \wedge tt \$	0
(1) $S \rightarrow S \wedge B$	tt	\wedge tt \$	4
(3) $S \rightarrow B$	B	\wedge tt \$	3
(4) $B \rightarrow tt$	S	\wedge tt \$	1
	S \wedge	tt \$	2
Input: tt \wedge tt	S \wedge tt	\$	4
	S \wedge B	\$	5
	S	\$	1

In der Spalte “Zustand” steht der Zustand des LR(0)-Automaten nach vollständigem Lesen des Stackinhalts.

Beispiel

Regeln:	Stack	Input	Zustand
(0) $S' \rightarrow S\$$	ε_0	tt \wedge tt \$	0
(1) $S \rightarrow S \wedge B$	ε_0 tt ₄	\wedge tt \$	4
(3) $S \rightarrow B$	ε_0 B ₃	\wedge tt \$	3
(4) $B \rightarrow tt$	ε_0 S ₁	\wedge tt \$	1
	ε_0 S ₁ \wedge_2	tt \$	2
Input: tt \wedge tt	ε_0 S ₁ \wedge_2 tt ₄	\$	4
	ε_0 S ₁ \wedge_2 B ₅	\$	5
	ε_0 S ₁	\$	1

Man muss nicht in jedem Schritt den gesamten Stackinhalt lesen. Man kann sich für jedes Symbol auf dem Stack den erreichten Zustand des LR(0)-Automaten merken. Dann muss man jeweils höchstens einen einzigen Schritt ausführen.

Implementierung: Parser-Tabelle

- Annotiere Stackeinträge mit erreichtem Automatenzustand (in der Praxis lässt man die ursprünglichen Stacksymbole ganz weg und arbeitet mit Automatenzuständen als Stackalphabet).
- Konstruiere Tabelle, deren Zeilen mit Zuständen und deren Spalten mit Grammatiksymbolen indiziert sind. Die Einträge enthalten eine der folgenden vier *Aktionen*:


Shift (n)	„Shift“ und gehe in Zustand n ;
Reduce (k)	„Reduce“ mit Regel k ;
Goto (n)	Gehe in Zustand n ;
Accept	Akzeptiere.

Leere Einträge bedeuten Syntaxfehler.

Der LR-Algorithmus

- Ermittle Aktion aus der Tabelle anhand des obersten Stackzustands und des nächsten Symbols.
- Ist die Aktion...
 - Shift(n):** Lies ein Zeichen weiter; lege Zustand n auf den Stack.
 - Reduce(k):**
 - Entferne soviele Symbole vom Stack, wie die rechte Seite von Produktion k lang ist,
 - Sei X die linke Seite der Produktion k :
 - Finde in Tabelle unter dem nunmehr oben liegenden Zustand und X eine Aktion „**Goto(n)**“;
 - Lege n auf den Stack.
 - Accept:** Ende der Analyse, akzeptiere die Eingabe.

Beispiel: LR(0)-Automat für Linksrekursion



Regeln:

(0) $S' \rightarrow S\$$


(1) $S \rightarrow S \wedge B$

(3) $S \rightarrow B$

(4) $B \rightarrow tt$

	tt	\wedge	\$	B	S
0	s4			g3	g1
1		s2	a		
2	s4			g5	
3	r3	r3	r3		
4	r4	r4	r4		
5	r1	r1	r1		

Rechtsrekursion



Regeln:

- (0) $S' \rightarrow S \$$
- (1) $S \rightarrow B \wedge S$
- (3) $S \rightarrow B$
- (4) $B \rightarrow tt$

Zustand 0: shift (tt)

Zustand 1: **Shift/Reduce-Konflikt**

Zustand 2: shift (tt)

Zustand 3:

Zustand 4: reduce (mit Regel 4)

Zustand 5: reduce (mit Regel 1)

In diesem Beispiel benötigt man einen LR(1)-Parser.

LR(1): Konstruktion des Automaten

Die Zustände haben die Form $(X \rightarrow \alpha.\beta, a)$ wobei $X \rightarrow \alpha\beta$ eine Produktion sein muss und a ein Terminalsymbol oder „?“ ist. Solch ein Zustand heißt **LR(1)-Item**.

Die Bedeutung diese Items entspricht der von $(X \rightarrow \alpha.\beta)$ mit der zusätzlichen Annahme, dass nach dem Lesen von β das nächste Eingabezeichen a ist.

Bei der Entscheidung, ob zu reduzieren ist, wird also das nächste Eingabezeichen berücksichtigt.

LR(1): Transitionen des Automaten

Die Zustandsübergänge des nichtdeterministischen Automaten sind wie folgt definiert:

- Startzustand des Automaten: $(S' \rightarrow .S\$, ?)$
- $(X \rightarrow \alpha.s\beta, a) \xrightarrow{s} (X \rightarrow \alpha s.\beta, a), s \in \Sigma \cup V,$
- $(X \rightarrow \alpha.Y\beta, a) \xrightarrow{\epsilon} (Y \rightarrow .\delta, b), \text{ falls } Y \rightarrow \delta \text{ und } b \in \text{FIRST}(\beta a)$
[Vervollständigung]

Man zeigt durch Induktion, dass der so definierte Automat tatsächlich die gewünschten Sprachen erkennt.

LR(1): Aktionen

Nun determinisiert man den Automaten und erhält so Mengen von LR(1)-Items als Zustände des Automaten. Der Automat wird auf den Stacksymbolen ausgeführt.

- Enthält der Endzustand das Item $(X \rightarrow \gamma., a)$ und ist das nächste Eingabesymbol a , so reduziert man mit $X \rightarrow \gamma$.
- Enthält der Endzustand das Item $(X \rightarrow \alpha.a\beta, c)$ und ist das nächste Eingabesymbol a , so wird geshiftet.

Gibt es mehrere Möglichkeiten, so liegt ein Shift/Reduce, beziehungsweise ein Reduce/Reduce-Konflikt vor und die Grammatik ist nicht LR(1).

LR(1): Beispiel

Grammatik:

(0) $S' \rightarrow S\$$

(1) $S \rightarrow E$

(2) $E \rightarrow E \wedge B$

(3) $E \rightarrow E \vee B$

(4) $E \rightarrow B$

(5) $B \rightarrow tt$

(6) $B \rightarrow ff$

Stack	Eingabe	Aktion
0	tt \wedge tt \$	shift 'tt'
0 2 _{tt}	\wedge tt \$	reduce (5) $B \rightarrow tt$
0 4 _B	\wedge tt \$	reduce (4) $E \rightarrow B$
0 3 _E	\wedge tt \$	shift ' \wedge '
0 3 _E 5 _{\wedge}	tt \$	shift 'tt'
0 3 _E 5 _{\wedge} 2 _{tt}	\$	reduce (5) $B \rightarrow tt$
0 3 _E 5 _{\wedge} 7 _B	\$	reduce (2) $E \rightarrow E \wedge B$
0 3 _E	\$	reduce (1) $S \rightarrow E$
0 9 _S	\$	accept

Eingabe: tt \wedge tt

	\wedge	\vee	ff	tt	\$	E	B	S
0			s1	s2		g3	g4	g9
1	r6	r6			r6			
2	r5	r5			r5			
3	s5	s6			r1			
4	r4	r4			r4			
5			s1	s2			g7	
6			s1	s2			g8	
7	r2	r2			r2			
8	r3	r3			r3			
9					acc			

LALR(1) und SLR

LR(1)-Tabellen sind recht groß (mehrere tausend Zustände für typische Programmiersprache).

LALR(1) ist eine heuristische Optimierung, bei der Zustände, die sich nur durch die Vorausschau-Symbole unterscheiden, identifiziert/zusammengelegt werden. Eine Grammatik heißt LALR(1), wenn nach diesem Prozess keine Konflikte entstehen.

Bei SLR wird auf Vorausschau-Symbole in den Items verzichtet, stattdessen verwendet man FOLLOW-Mengen, um Konflikte aufzulösen.

JavaCUP

JavaCUP generiert LALR(1) Parser.

```
java -jar java-cup-11a.jar input_file.cup
```

Von JavaCUP gemeldete Konflikte muss man ernst nehmen; in den meisten Fällen deuten sie auf Fehler in der Grammatik hin.

Mit der Option `-dump` wird der LR-Automat mit eventuellen Konflikten ausgegeben.

```
java -jar java-cup-11a.jar -dump input_file.cup
```

Man kann Konflikte durch Regelprioritäten lösen. Das ist aber nur sehr selten sinnvoll, z.B. bei „dangling else“:

$S \rightarrow \text{if } E \text{ then } S$


$S \rightarrow \text{if } E \text{ then } S \text{ else } S$

Im

MiniJava-Parser sollten nach Beachtung der Operatorpräzedenzen keine Konflikte mehr enthalten sein.

Überblick

Grammatikklassen



Sprachklassen

$$LL(1) \subsetneq LL(2) \subsetneq \dots \subsetneq LR(1) = LR(2) = \dots = L(DPDA) \subsetneq L(CFG)$$

Ihre heutige Aufgabe

Stellen Sie die JavaCUP-Grammatik für MiniJava fertig.

- Lösen Sie *alle* Konflikte in Ihrer MiniJava-Grammatik.

Erweitern Sie Ihren Parser so, dass er einen abstrakten Syntaxbaum erzeugt.

- Im git-Repository finden Sie Klassen, mit denen die abstrakten Syntaxbäume von MiniJava repräsentiert werden können.
- Schreiben Sie semantische Aktionen für jede Regel, sodass entsprechende AST-Knoten erzeugt und mit den Unterknoten verbunden werden.
- Die Klasse Program hat eine Methode prettyPrint, mit der den eingelesenen Syntaxbaum wieder in einen String umwandeln kann. Testen Sie Ihren Parser damit.

Semantische Aktionen

```
/* Terminalsymbole */
terminal String IDENTIFIER;
terminal Integer INT;
terminal EQ;
...

/* Nichtterminalsymbole */
non terminal Stm Stm;
non terminal Exp Exp;
non terminal List<Exp> ExpList;

/* Grammatik */
Exp ::= Exp:e1 PLUS Exp:e2  {: RESULT = new Exp.OpExp(e1, Binop.PLUS, e2); :}
      | INT:num              {: RESULT = new Exp.NumExp(num); :}
      | LPAREN Exp:e RPAREN  {: RESULT = e; :}
      ...

ExpList ::= Exp:e             {: RESULT = Collections.singletonList(e); :}
          | ExpList:es COMMA Exp:e
            {: LinkedList<Exp> exps = new LinkedList<Exp>(es);
              exps.add(e);
              RESULT = exps;
            :}
          ;
```

Semantische Aktionen

```
/* Terminalsymbole */
terminal String IDENTIFIER;
terminal Integer INT;
terminal EQ;
...

/* Nichtterminalsymbole */
non terminal Stm Stm;
non terminal Exp Exp;
non terminal List<Exp> ExpList;

/* Grammatik */
Exp ::= Exp:e1 PLUS Exp:e2 { : RESULT = new Exp.OpExp(e1, Binop.PLUS, e2); :}
      | INT:num { : RESULT = new Exp.NumExp(num); :}
      | LPAREN Exp:e RPAREN { : RESULT = e; :}
...

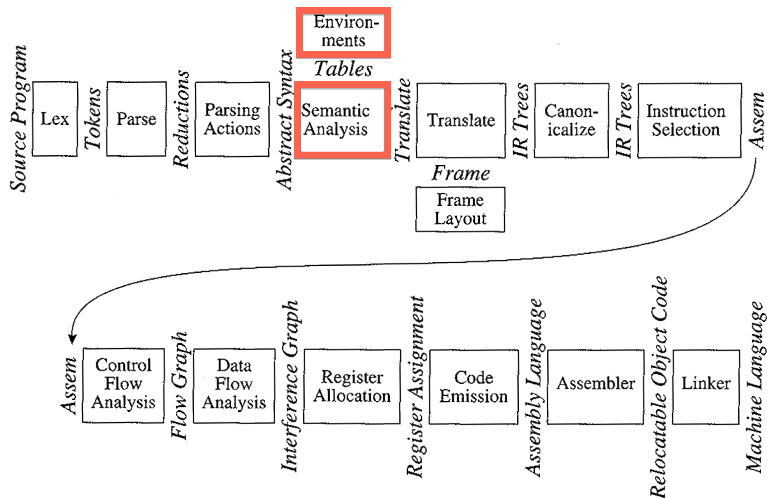
ExpList ::= Exp:e { : RESULT = Collections.singletonList(e); :}
          | ExpList:es COMMA Exp:e
            { : LinkedList<Exp> exps = new LinkedList<Exp>(es);
              exps.add(e);
              RESULT = exps;
            :}
;
;
```

Java-Typen (Typen der Ergebniswerte)

Java-Variablennamen für Teilergebnisse

Semantische Analyse

Semantische Analyse



Semantische Analyse

Fron-End muss prüfen, ob die Eingabe ein gültiges Programm der Eingabesprache ist.

Bisher:

- Lexikalische Analyse
(endlicher Automat)
- Syntaktische Analyse
(kontextfreie Grammatik)

Endliche Automaten und Kontextfreie Grammatiken sind nicht ausdrucksstark genug, um die Korrektheit von Programmen zu entscheiden. \Rightarrow Semantische Analyse

Semantische Analyse

In der semantischen Analyse im Front-End wird die abstrakte Syntax auf Gültigkeit überprüft:

- Typkorrektheit
- Alle Variablen werden deklariert bevor sie benutzt werden.
- Jede Methode hat return-Statements in jedem Lauf.
- Mögliche Exceptions sind mit throws-Klausel deklariert.
- ...

Bei möglicherweise ungewolltem Code werden Warnungen ausgegeben.

Semantische Informationen können auch später im Compiler nützlich sein, z.B. Typinformationen.

Semantische Analyse

In der ersten Phase wird das Programm üblicherweise nur auf Korrektheit geprüft. Weitere semantische Analysen können später stattfinden.

Beispiele für Analysen, die *erst später* durchgeführt werden.

- Wertebereiche genauer analysieren als durch die Typen vorgegeben, z.B. $0 < i < 100$.

```
for (int i = 1; i < 100; i++) { if (i < 1000) a[i]++; }
```

Test wird von aktuellen C-Compilern entfernt.

- Werden Zwischenergebnisse im Endergebnis überhaupt verwendet? Z.B. Entfernung von assert-Statements

```
if (debug) { ... }
```

- Wie lange kann auf Variablen zugegriffen werden? Speicherung in Register oder Hauptspeicher?
- Kontrollflussanalyse
- ...

Typüberprüfung

Ein Hauptteil der semantischen Analyse im Front-End ist die statische Typüberprüfung.

Statische Typsysteme

- Teil der Sprachdefinition
- Ausschluss von Laufzeitfehlern durch Typanalyse („Well-typed programs can't go wrong“ — Milner 1978)
- Typüberprüfung
- Typinferenz

Typinformationen im Compiler

- Generierung von besserem/effizienterem Code
- Ausschluss unsinniger Fälle
- Fehlervermeidung durch typisierte Zwischensprachen

Typüberprüfung

Für MiniJava kann die Typüberprüfung durch einen einmaligen Durchlauf des gesamten Programms implementiert werden, in dem alle Teile des Programms auf Typkorrektheit überprüft werden.

```
class C {                                ✓
    public int m () {                    ✓
        int i; D d;                     ✓
        d = new D();                   ✓
        i = d.f() + 2;                  ✓
        i = d.g(i);                     ✗
    }
}

class D {
    public int f() {...}
    public int g(boolean b) {...}
}
```

Symboltabelle

Es nützlich eine *Symboltabelle* anzulegen, in der z.B. Typinformationen für alle Identifier im Programm abgelegt werden.

```
class C {  
    public int m () {  
        int i; D d;  
        d = new D();  
        i = d.f() + 2; // Schlage hier den Typ von f in der  
                      // Symboltabelle nach (statt die Datei  
                      // nach der Definition zu durchsuchen).  
        ...  
    }  
}  
  
class D {  
    public int f() {...}  
    ...  
}
```

Symboltabellen können weitere Informationen enthalten und sind an vielen Stellen des Compilers nützlich.

Symboltabelle für MiniJava

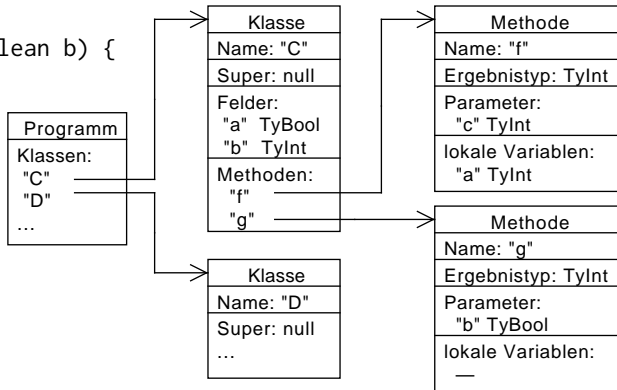
Eine Symboltabelle bildet Bezeichner ab auf „semantische Werte“.

- Semantischer Wert eines **Programms**:
 - Klassennamen mit ihren semantischen Werten
- Semantischer Wert einer **Klasse**:
 - Instanzvariablen mit ihren semantischen Werten (Ordnung wichtig)
 - Methodennamen mit ihren semantischen Werten
 - Verweis auf den Eintrag der Elternklasse
- Semantischer Wert einer **Instanzvariable**:
 - Typ
- Semantischer Wert einer **Methode**:
 - Ergebnistyp
 - Liste der Parameter mit ihren Typen (Ordnung wichtig)
 - lokale Variablen mit ihren Typen
 - Kann IOException ausgelöst werden?

Symboltabelle – Beispiel

```
class C {  
    boolean a;  
    int b;  
    public int f (int c) {  
        int a;  
        return a+b+c;  
    }  
    public int g (boolean b) {  
        return b+1;  
    }  
}
```

```
class D {  
    ...  
}
```



Typüberprüfung für MiniJava

Die Typüberprüfung selbst besteht nun aus einem Satz von Methoden, welche in Gegenwart einer Symboltabelle die verschiedenen Programmteile auf Typkorrektheit prüfen:

- Programm
- Klasse
- Methode
- Statement
- Expression

Wir betrachten zunächst MiniJava ohne Vererbung.

Typüberprüfung — Expressions

Für die Typüberprüfung ist es normalerweise nötig, den Typ eines gegebenen Ausdrucks auszurechnen (Typinferenz).

$typeOf(x)$ = Typ der Variablen x nachschlagen:

1. lokale Variablen, 2. Methodenparameter,
3. Instanzvariable der Klasse, (4. Superklasse ...)

$$typeOf(e_1 + e_2) = \begin{cases} \text{int} & \text{wenn } typeOf(e_1) = typeOf(e_2) = \text{int} \\ \perp & \text{sonst} \end{cases}$$

$$typeOf(e_1.m(e_2)) = \begin{cases} t & \text{wenn } typeOf(e_1) = C \text{ und} \\ & \text{Klasse } C \text{ hat Methode } t \text{ } m(typeOf(e_2) \ x) \\ \perp & \text{sonst} \end{cases}$$

Kompositionalität: Der Typ eines Ausdrucks ist durch die Typen seiner direkten Teilausdrücke bestimmt.

Implementierung mittels Visitor für Exp, analog zu PrettyPrint.

Typüberprüfung — Statements

Programmanweisungen (Statements) haben selbst keinen Typ, sie können nur wohlgetypt sein oder nicht.

Implementierung durch eine Funktion, die entscheidet, ob ein gegebenes Statement wohlgetypt ist:

$$typeOk(x = e) = \begin{cases} true & \text{wenn } typeOf(e) = typeOf(x) \\ false & \text{sonst} \end{cases}$$

$$typeOk(System.out.println(e)) = \begin{cases} true & \text{wenn } typeOf(e) = int \\ false & \text{sonst} \end{cases}$$

...

Typüberprüfung — Methode

```
public int f (int c, ...) {  
    int a;  
    ...  
    s  
    return e;  
}
```

Es werden folgende Bedingungen geprüft:

- Die Parameter und die lokalen Variablen haben paarweise verschiedene Namen.
Instanzvariablen dürfen aber überschattet werden.
- Die Anweisung `s` ist wohlgetypt.
- Der Typ von `e` entspricht dem Rückgabetypt der Funktion.
- Wenn in der Methode eine `IOException` ausgelöst werden kann, dann ist das auch deklariert.

Typüberprüfung — Klasse, Programm

Klasse

Um eine Klasse zu überprüfen, werden alle Methoden überprüft.
Es wird geprüft, dass keine Methode doppelt definiert ist.
Beachte: Die Methode `main` ist statisch und darf nicht auf `this` zugreifen!

Programm

Um ein Programm zu überprüfen, werden alle Klassen überprüft.
Es wird geprüft, dass keine Klasse mehrfach definiert ist.

Ihre Aufgabe

Implementieren Sie die Typüberprüfung für MiniJava ohne Vererbung.

Es bietet sich an, die Implementierung in zwei Phasen zu gliedern:

1. Erzeugung der Symboltabelle.

Die Klassen und Methoden des Eingabeprogramms werden einmal durchgegangen und die Symboltabelle wird dabei schrittweise aufgebaut.

2. Typüberprüfung.

Im zweiten Schritt wird das Programm noch einmal komplett durchgegangen. Nun kann die Symboltabelle benutzt werden, um die Eingabe auf Typkorrektheit zu überprüfen.

Ihre Aufgabe

Milestone 1: Parser und Typchecker

Schreiben Sie ein Hauptprogramm, das folgenden Anforderungen genügt:

1. Einlesen einer MiniJava-Datei, deren Dateiname als erstes Kommandozeilenargument gegeben ist.
2. Eingabe wird auf syntaktische Korrektheit sowie Typkorrektheit überprüft.
3. Ist die Eingabe ein korrektes MiniJava-Programm, soll das Programm mit Exit-Code 0 beendet werden. Andernfalls soll der Exit-Code $\neq 0$ sein. (`System.exit(exitcode);`).

Empfehlung: Automatisieren Sie Tests Ihres Compilers, mindestens mit den gegebenen Beispielprogrammen, gerne auch mit eigenen Testfällen.

Umgang mit Gültigkeitsbereichen

MiniJava hat ein sehr einfaches Typsystem, das die Behandlung von Variablen besonders einfach macht.

Nahezu alle Sprachen erlauben kompliziertere Gültigkeitsbereiche für Variablen.

```
class C {  
    int a; int b; int c;  
    public void m () {  
        System.out.println(a+c);  
        int j = a+b;  
        String a = "hello";  
        System.out.println(a);  
        for (int k = 0; k < 23; k++) {  
            System.out.println(j+k);  
        }  
        . . .  
    }  
}
```

Umgang mit Gültigkeitsbereichen

Man verwendet *Umgebungen*, um die Gültigkeit von Variablen zu verfolgen.

Eine Umgebung Γ ist eine Abbildung von Variablennamen auf semantische Werte, z.B. Typen.

class C {	$\Gamma_0 = \{g \mapsto \text{String}, a \mapsto \text{int}[]\}$
int a; int b; int c;	$\Gamma_1 = \Gamma_0 + \{a \mapsto \text{int}, b \mapsto \text{int}, c \mapsto \text{int}\}$
public void m () {	
System.out.println(a+c);	
int j = a+b;	$\Gamma_2 = \Gamma_1 + \{j \mapsto \text{int}\}$
String a = "hello";	$\Gamma_3 = \Gamma_2 + \{a \mapsto \text{String}\}$
System.out.println(a);	
for (int k = 0; k < 23; k++) {	
System.out.println(j+k);	$\Gamma_4 = \Gamma_3 + \{k \mapsto \text{int}\}$
}	Γ_3
...	

Hierbei steht $\Gamma + \Delta$ für die Umgebung, die man erhält, wenn man in Γ alle von Δ definierten Variablen durch ihre Werte in Δ überschreibt.

Typüberprüfung mit Gültigkeitsbereichen

Die Funktionen *typeOf* und *typeOk* hängen nun auch von der Umgebung ab.


$$\text{typeOf}(\Gamma, e) = \dots$$

$$\text{typeOk}(\Gamma, s) = \dots$$

Im Fall für Variablen wird der Typ nun zunächst in der Umgebung nachgeschlagen.

Implementierung von Umgebungen

Umgebungen können als hierarchische Hash-/TreeMaps implementiert werden:



- Betreten eines Blocks durch Hinzufügen einer neuen Tabelle, deren outer-Feld zur Tabelle des aktuellen Gültigkeitsbereichs zeigt.
- Verlassen eines Gültigkeitsbereichs durch Löschen der aktuellen Tabelle. Die durch outer referenzierte Tabelle wird die neue aktuelle Tabelle.
- Um den Typ einer Variablen zu ermitteln, wird zuerst in der aktuellen Tabelle nachgeschaut, dann in der outer-Tabelle

Umgang mit Vererbung

Bei Einfachvererbung kann die Sichtbarkeit von Methoden und Feldern wie bei den Umgebungen implementiert werden (super spielt die Rolle von outer).

Die Typisierungsregeln müssen modifiziert werden, um der Unterklassenrelation \leq Rechnung zu tragen.

Beispiele

$$\frac{e_1 : C \leq D \quad D \text{ hat Methode } t'_1 m(t'_2) \text{ mit } t'_1 \leq t_1 \quad e_2 : t_2 \leq t'_2}{e_1.m(e_2) : t_1}$$

$$\frac{x : t \quad e : t' \quad t' \leq t}{x := e \text{ ok}}$$

Optionale Aufgaben

- benutzerfreundliche Fehlermeldungen
- Vererbung
- lokale Variablendeklarationen